

ВЫБОР ARIMA И ПРОГНОЗИРОВАНИЕ

ПОДБОР ПАРАМЕТРОВ



› α, ϕ, θ

› d, D

› q, Q

› p, P

- › Если все остальные параметры фиксированы, коэффициенты регрессии подбираются методом наименьших квадратов
- › Чтобы найти коэффициенты θ , шумовая компонента предварительно оценивается с помощью остатков авторегрессии
- › Если шум белый (независимый одинаково распределённый гауссовский), то МНК даёт оценки максимального правдоподобия

- › Порядки дифференцирования подбираются так, чтобы ряд стал стационарным
- › Ещё раз: если ряд сезонный, рекомендуется начинать с сезонного дифференцирования
- › Чем меньше раз мы продифференцируем, тем меньше будет дисперсия итогового прогноза



- › Гиперпараметры нельзя выбирать из принципа максимума правдоподобия: L всегда увеличивается с их ростом
- › Для сравнения моделей с разными q, Q, p, P можно использовать критерий Акаике:
$$AIC = -2 \ln L + 2k,$$
$$k = P + Q + p + q + 1$$
 — число параметров в модели
- › Начальные приближения можно выбрать с помощью автокорреляций

- › $Q * S$ — номер последнего сезонного лага, при котором автокорреляция значима (здесь 0)
- › q — номер последнего несезонного лага, при котором автокорреляция значима (здесь 8)


q, Q

» $Q * S$ — номер последнего сезонного лага, при котором автокорреляция значима (здесь 0)

» q — номер последнего несезонного лага, при котором автокорреляция значима (здесь 8)




- » Частичная автокорреляция — автокорреляция после снятия авторегрессии предыдущего порядка



- › $P * S$ — номер последнего сезонного лага, при котором частичная автокорреляция значима (здесь 2)
- › p — номер последнего несезонного лага, при котором частичная автокорреляция значима (здесь 1)

РЕАЛЬНАЯ ЗАРАБОТНАЯ ПЛАТА

- › Перебирая модели с $D = 1, d = 0$ и преобразованием Бокса-Кокса, получаем наименьший AIC на $ARIMA(2, 0, 1) \times (2, 1, 2)$:



- › Смотрим на ряд
- › При необходимости стабилизируем дисперсию
- › Если ряд нестационарен, подбираем порядок дифференцирования
- › Анализируем ACF/PACF, определяем примерные p, q, P, Q
- › Обучаем модели-кандидаты, сравниваем их по AIC, выбираем победителя
- › Смотрим на остатки полученной модели, если они плохие, пробуем что-то поменять

$$y_t = \hat{\alpha} + \hat{\phi}_1 y_{t-1} + \cdots + \hat{\phi}_p y_{t-p} + \\ + \varepsilon_t + \hat{\theta}_1 \varepsilon_{t-1} + \cdots + \hat{\theta}_q \varepsilon_{t-q}$$

➤ Заменяем t на $T + 1$

$$\hat{y}_{T+1|T} = \hat{\alpha} + \hat{\phi}_1 y_T + \dots + \hat{\phi}_p y_{T+1-p} + \\ + \varepsilon_{T+1} + \hat{\theta}_1 \varepsilon_T + \dots + \hat{\theta}_q \varepsilon_{T+1-q}$$

$$\hat{y}_{T+1|T} = \hat{\alpha} + \hat{\phi}_1 y_T + \dots + \hat{\phi}_p y_{T+1-p} + \\ + \varepsilon_{T+1} + \hat{\theta}_1 \varepsilon_T + \dots + \hat{\theta}_q \varepsilon_{T+1-q}$$

➤ Заменяем будущие ошибки на нули:

$$\hat{y}_{T+1|T} = \hat{\alpha} + \hat{\phi}_1 y_T + \dots + \hat{\phi}_p y_{T+1-p} + \\ + \hat{\theta}_1 \varepsilon_T + \dots + \hat{\theta}_q \varepsilon_{T+1-q}$$


➤ Заменяем прошлые ошибки на остатки:

$$\hat{y}_{T+1|T} = \hat{\alpha} + \hat{\phi}_1 y_T + \dots + \hat{\phi}_p y_{T+1-p} + \\ + \hat{\theta}_1 \hat{\varepsilon}_T + \dots + \hat{\theta}_q \hat{\varepsilon}_{T+1-q}$$

- › Если мы прогнозируем на момент времени $T + 2$, в формуле появляется значение ряда из будущего:

$$\hat{y}_{T+2|T} = \hat{\alpha} + \hat{\phi}_1 y_{T+1} + \dots + \hat{\phi}_p y_{T+2-p} + \\ + \hat{\theta}_1 \hat{\varepsilon}_{T+1} + \dots + \hat{\theta}_q \hat{\varepsilon}_{T+2-q}$$

- › Заменяем его на прогноз $\hat{y}_{T+1|T}$



- › Подбор параметров модели
- › Прогнозирование

ДАЛЕЕ В ПРОГРАММЕ

- › Как понять, что модель достаточно хороша?
- › Анализ остатков